Diagnóstico de vinos con redes densas: comparación de optimizadores y regularización

Carlos Mario Salvatore Ocampo Aguilar

Especialización en Inteligencia Artificial

Universidad de Cundinamarca

604010 – Redes Neuronales III

R2-A1-S7 – Optimización y regularización

10 de octubre de 2026

Diagnóstico de vinos con redes densas: comparación de optimizadores y regularización

Planteamiento y control de datos

Se estudió una clasificación pequeña de tres variedades de vino mediante 13 mediciones fisicoquímicas. *Wine* tiene 178 observaciones; su tamaño hace que una única partición no baste para afirmar estabilidad poblacional (scikit-learn, s. f.). La red $13 \to 64 \to 32 \to 3$ utilizó ReLU y entropía cruzada sobre logits.

Primero se apartó prueba; el resto se dividió entre entrenamiento y desarrollo manteniendo las proporciones de clase. La Tabla 1 documenta los tamaños. Se ajustó `StandardScaler` solo con entrenamiento y se transformaron desarrollo y prueba con los mismos parámetros. Esta secuencia evita filtrar información de prueba al aprendizaje. También se comprobó que no hubiera índices compartidos ni valores no finitos.

Tabla 1
Protocolo experimental

Elemento	Especificación
Conjunto	Wine: 178, 13 variables, 3 clases
Entrenamiento / desarrollo / prueba	106 / 36 / 36
Partición	Estratificada; prueba aislada para evaluación final
Preprocesamiento	Escalador ajustado solo en entrenamiento
Semillas de inicialización	19, 31, 43
Tamaño de lote y máximo de épocas	16 y 180
Criterio de selección	Mayor F1 macro medio en desarrollo

Nota. Diseño y ejecución propios; los tamaños provienen del conjunto cargado.

Comparación controlada

La Tabla 2 registra las cinco variantes. SGD con momento, RMSprop y AdamW proporcionan tres reglas de actualización. En AdamW, el decaimiento de pesos está desacoplado de la actualización adaptativa; no es idéntico a sumar una penalización L2 al objetivo de Adam (Loshchilov & Hutter, 2019; PyTorch, s. f.). La variante completa añade dropout 0, 15, parada tras 16 épocas sin una mejora de pérdida mayor que 10^{-5} y reducción de tasa a la mitad tras seis épocas de estancamiento. Se restauró el mejor estado de desarrollo.

Las otras variantes finalizaron a 180 épocas. Cada una se repitió con tres semillas, manteniendo fija la partición; las tres corridas no son validación cruzada. El test quedó cerrado hasta después de elegir la configuración con F1 macro medio de desarrollo.

Tabla 2
Configuraciones ensayadas

Optimizador y variante	Tasa	Decaimiento	Dropout	Parada
`SGD_momentum`	0,0350	0,000	0,00	No
`AdamW_base`	0,0030	0,000	0,00	No
`RMSprop`	0,0015	0,000	0,00	No
`AdamW_decay`	0,0030	0,001	0,00	No
`AdamW_completo`	0,0030	0,001	0,15	Sí

Nota. Quince ajustes por persona: cinco configuraciones y tres semillas. La tasa de SGD y RMSprop se fijó antes de comparar; no se hizo búsqueda exhaustiva.

La implementación principal conserva el aislamiento de datos. Estos fragmentos muestran el escalado, AdamW y la medición macro:

```
escalador = StandardScaler().fit(x[it])
normal = escalador.transform(x).astype(np.float32)
opt = torch.optim.AdamW(modelo.parameters(), lr=.003,
                        weight_decay=.001)
precision, recall, f1, _ = precision_recall_fscore_support(
    y.numpy(), pred, average='macro', zero_division=0)
```

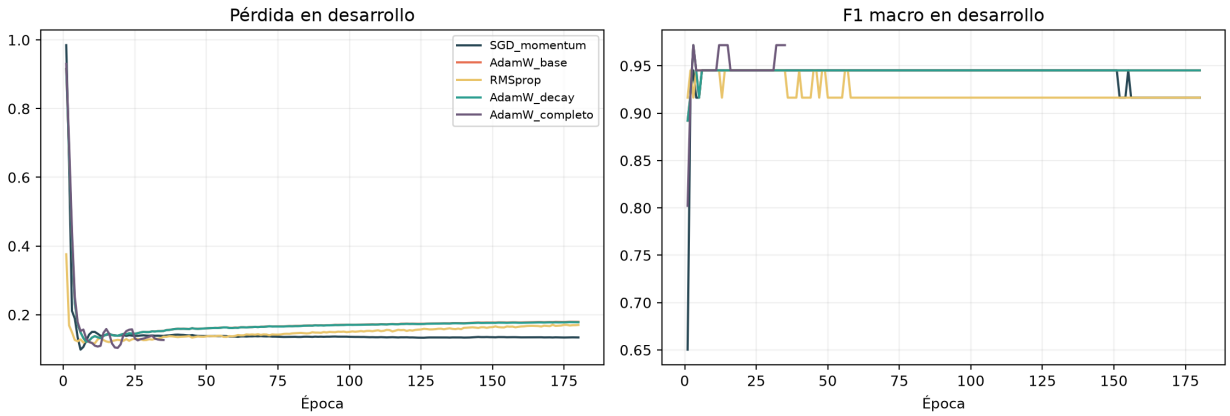
Un modelo con mucho sesgo no separaría ni los datos de entrenamiento; uno con alta varianza podría memorizar ese conjunto y fallar en datos nuevos. La regularización busca equilibrarlos, pero aquí 36 casos de desarrollo y una sola partición limitan la precisión de esa lectura.

Evidencia de desarrollo

La Figura 1 muestra cómo se mueve cada método para la semilla 19. La Tabla 3 promedia tres inicializaciones. El F1 macro da igual peso a las clases y evita que una clase numerosa oculte una pequeña; la desviación estándar advierte sobre variación por semilla. Una diferencia pequeña entre configuraciones en 36 muestras de desarrollo no debe interpretarse como superioridad universal.

Figura 1

Pérdida y F1 en desarrollo por optimizador



Nota. Resultados propios, semilla 19; las demás curvas están en los CSV.

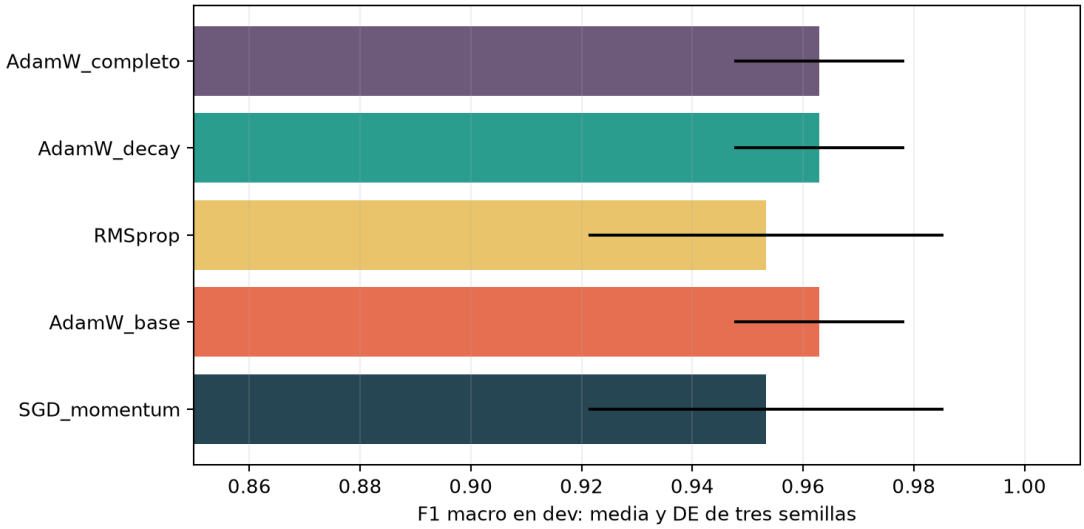
Tabla 3

Resultados de desarrollo en tres semillas

Configuración	F1 macro medio	DE	Pérdida	Brecha F1
`SGD_momentum`	0,9533	0,0320	0,1426	0,0467
`AdamW_base`	0,9629	0,0154	0,1571	0,0371
`RMSprop`	0,9533	0,0320	0,1517	0,0467
`AdamW_decay`	0,9629	0,0154	0,1561	0,0371
`AdamW_completo`	0,9629	0,0154	0,0945	0,0371

Nota. DE: desviación estándar muestral. Brecha = F1 de entrenamiento menos F1 de desarrollo. Todas las cifras proceden de las corridas guardadas en `experimentos_dev.csv`.

Figura 2
Dispersión de F1 en las tres semillas

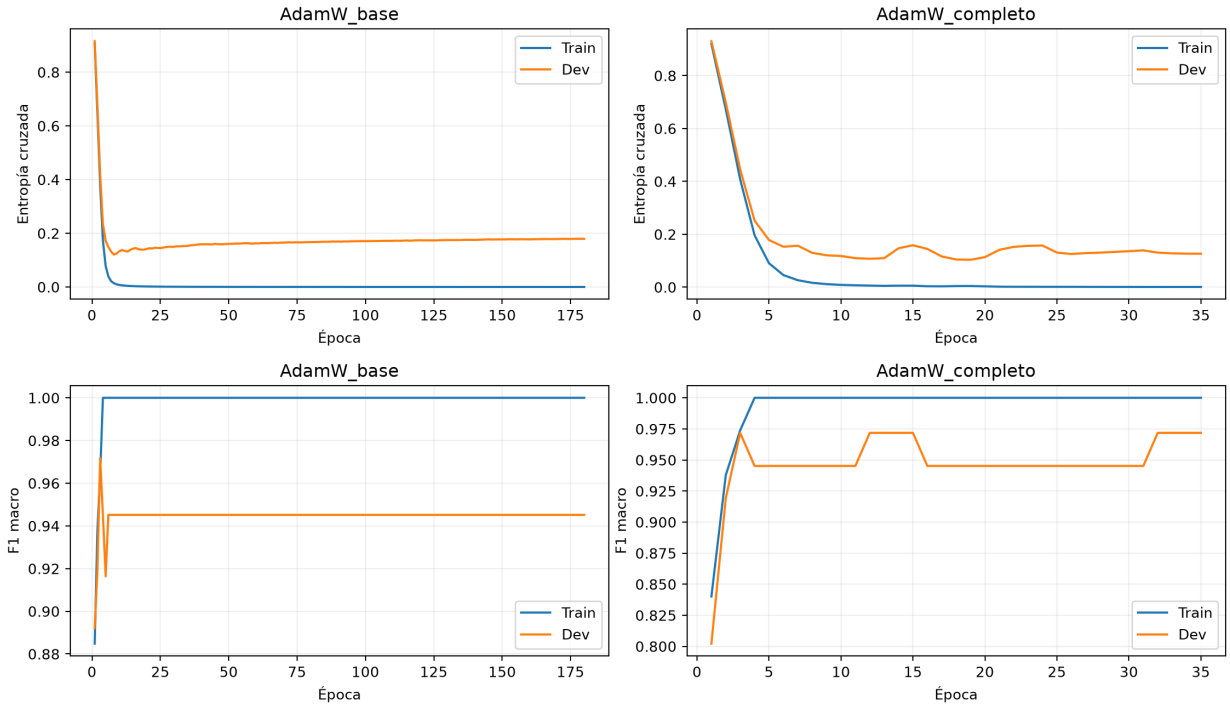


Nota. Barras calculadas a partir de la misma partición de desarrollo.

El mayor F1 medio de desarrollo correspondió a `AdamW_completo`; la cifra fue 0,9629. La Figura 3 compara entrenamiento y desarrollo en pérdida y F1 para AdamW base y completo. La parada temprana acorta la exposición de la red a un conjunto de entrenamiento pequeño, pero el gráfico no aísla por sí solo el efecto de dropout del programador.

Figura 3

Efectos observados de la política completa



Nota. Columnas: AdamW base y completo; filas: pérdida y F1. Semilla 19.

Prueba separada e interpretación

La Tabla 4 corresponde exclusivamente a la configuración elegida. Se calcularon exactitud, precisión, exhaustividad y F1 macro, además de la pérdida. La Figura 4 es la matriz de confusión para la primera semilla. En sus 36 casos todos quedaron en la diagonal; ello documenta este test, no una tasa de error verdadera igual a cero. Con un conjunto tan pequeño, un error adicional cambiaría la exactitud en aproximadamente 1/36.

Tabla 4

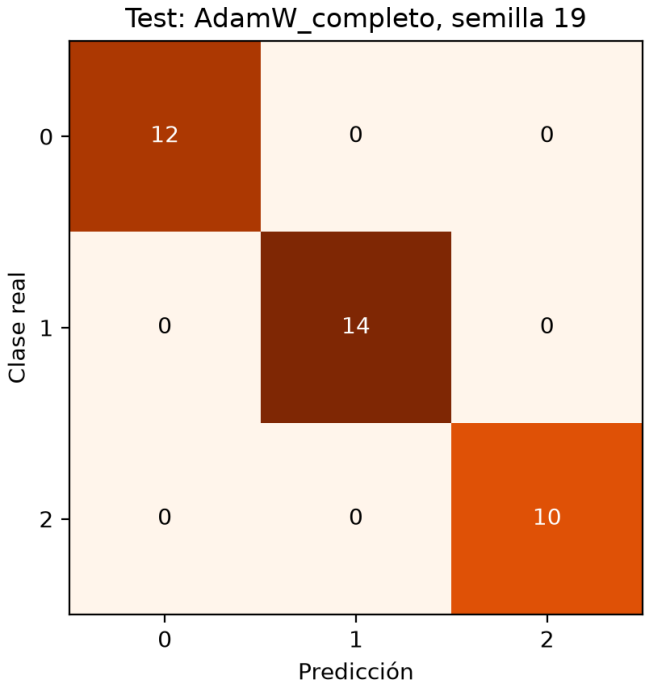
Evaluación final de la configuración elegida

Semilla	Exactitud	Precisión	Exhaustividad	F1 macro	Pérdida
19	1,0000	1,0000	1,0000	1,0000	0,0040
31	1,0000	1,0000	1,0000	1,0000	0,0180
43	1,0000	1,0000	1,0000	1,0000	0,0052

Nota. Prueba consultada solo después de elegir la configuración en desarrollo. Métricas macro: media no ponderada por clase.

Figura 4

Matriz de confusión en 36 observaciones de prueba



Nota. Modelo seleccionado, semilla 19; filas reales y columnas predichas.

Conclusión y reproducibilidad

En este corte de Wine, la política completa fue elegida por desarrollo y acertó las 36 observaciones de prueba en las tres inicializaciones. Es una observación fuerte del experimento, pero frágil como promesa de desempeño en muestras futuras. Se requeriría evaluación externa o validación repetida de particiones para cuantificar esa incertidumbre.

Se entregan script, cuaderno, partición por índices, 15 historiales, configuraciones, predicciones y modelo seleccionado. La ejecución registrada fue local en CPU; el cuaderno se preparó para abrir en Colab, sin atribuirle una ejecución que no se realizó allí.

El repositorio público con el cuaderno y las evidencias se encuentra en https://github.com/Salv4tore27/carlos-redes-neuronales-iii-vinos.

Referencias

Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. *International Conference on Learning Representations*. https://openreview.net/forum?id=Bkg6RiCqY7

PyTorch. (s. f.). *AdamW*. https://docs.pytorch.org/docs/main/generated/torch.optim.AdamW.html

scikit-learn. (s. f.). *load_wine*. https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_wine.html